

1. รายงานปัญหาที่พบ

จากชุดข้อมูลตั้งต้นทั้งหมด 480 รายการ พบปัญหาด้านคุณภาพข้อมูล (Data Quality Issues) 3 ประเภทหลัก รวมทั้งหมด 57 จุด ดังนี้ครับ:

- ข้อมูลซ้ำซ้อน (Duplicates): พบข้อมูลที่บันทึกซ้ำกันจำนวน 25 รายการ
- ข้อมูลสูญหาย (Missing Values): พบค่าว่างในข้อมูลรวม 17 จุด กระจายอยู่ใน 4 คอลัมน์ ได้แก่
 - temp_c (อุณหภูมิ): หายไป 7 จุด
 - motion (การเคลื่อนไหว): หายไป 4 จุด
 - battery (แบตเตอรี่): หายไป 4 จุด
 - device_id (รหัสอุปกรณ์): หายไป 2 จุด
- ข้อมูลผิดปกติ (Outliers): พบค่าที่กระโดดผิดปกติจากความเป็นจริงรวม 15 จุด แบ่งเป็น
 - อุณหภูมิผิดปกติ (Temperature Outlier): 10 จุด
 - แบตเตอรี่ผิดปกติ (Battery Outlier): 5 จุด

2. เปรียบเทียบจำนวนแถวก่อนและหลังทำความสะอาด

- จำนวนแถวก่อนทำความสะอาด (Rows before): 480 แถว
- จำนวนแถวหลังทำความสะอาด (Rows after): 455 แถว
- ส่วนต่าง: ลดลง 25 แถว * ข้อสังเกต: จำนวนแถวที่ลดลง (25 แถว) มาจากการลบ "ข้อมูลซ้ำซ้อน (Duplicates)" ออกไปทั้งหมด ส่วนปัญหาค่าว่างและค่าผิดปกติใช้วิธีการจัดการแบบอื่น (เช่น การเติมค่า Imputation หรือการปรับแก้ค่า) ทำให้จำนวนแถวสุทธิไม่ลดลงไปกว่านี้ และชุดข้อมูลหลังทำความสะอาดไม่มีค่าว่างหลงเหลืออยู่เลย